

UNIVERSITATEA POLITEHNICA DIN BUCUREȘTI

Facultatea de Automatică și Calculatoare

Master: Știința Datelor

OPTIMIZAREA STRATEGIEI DE PIT STOP ÎN FORMULA 1

Student:

Vlădeanu Ionuț

București, 2026

CUPRINS

PARTEA I: COLECTAREA ȘI PROCESAREA DATELOR	3
1. Introducere și Context	3
1.1 Contextul Formula 1 ca Problemă de Optimizare Decizională	3
1.2 Importanța Strategiei de Pit Stop în Performanța de Cursă	3
1.3 Scopul și Obiectivele Proiectului	3
2. Arhitectura Pipeline-ului de Colectare a Datelor	4
2.1 Viziune de Ansamblu	4
2.2 Tehnologii și Biblioteci Utilizate	4
3. Sursa și Structura Datelor	4
3.1 Universul de Date: Sezonul 2024	5
3.2 Procesul de Extragere a Datelor	5
4. Ingineria Caracteristicilor (Feature Engineering)	6
4.1 Caracteristici Lag (Istorice)	6
4.2 Estimarea Degradării	6
4.3 Estimarea Pierderii de Timp la Pit Stop	6
5. Structura Finală a Datasetului	6
PARTEA II: ANALIZA EXPLORATORIE A DATELOR (EDA)	7
6. Obiectivele Analizei Exploratorii	7
7. Inspecția Inițială a Datasetului	7
7.1 Dimensiuni și Structură	7
7.2 Categori de Variabile	7
8. Analiza Valorilor Lipsă	7
9. Distribuții ale Variabilelor Numerice	8
9.1 lap_time_s (Timpul pe Tur)	8
9.2 tyre_age_laps (Vârsta Anvelopei)	8
9.3 degradation_s_per_lap (Rata de Degradare)	8
10. Distribuții ale Variabilelor Categorice	8
10.1 compound (Tipul de Anvelopă)	8
10.2 safety_car_flag și virtual_sc_flag	8
PARTEA III: ANTRENAREA MODELULUI DE MACHINE LEARNING	10
11. Obiectivele Antrenării Modelului	10
11.1 Abordarea Multi-Task Learning	10
12. Feature Engineering pentru Model	10
12.1 Crearea Variabilelor Țintă	10
12.2 Selecția Caracteristicilor	10
13. Strategia de Împărțire Train/Test	10
13.1 Împărțirea Cronologică	10
13.2 Gestionarea Dezechilibrului cu SMOTE	10
14. Antrenarea și Compararea Modelelor	11
14.1 Modelele Testate	11
15. Calibrarea Probabilităților	11

15.1 Problema Probabilităților Necalibrate	11
15.2 Soluția: Isotonic Regression	11
16. Analiza Importanței Caracteristicilor	11
PARTEA IV: GENERATORUL DE STRATEGIE	13
17. Introducere în Generatorul de Strategie	13
17.1 Arhitectura Generatorului	13
18. Profiluri de Circuite	13
19. Configurarea Simulării	13
19.1 Parametri Cheie	13
20. Logica de Decizie	13
21. Validarea Recomandărilor	14
CONCLUZII	15
Realizări Principale	15
Caracteristici Cheie Identificate	15
Limitări și Direcții Viitoare	15
Contribuția Proiectului	15
BIBLIOGRAFIE	16

PARTEA I: COLECTAREA ȘI PROCESAREA DATELOR

1. Introducere și Context

1.1 Contextul Formula 1 ca Problemă de Optimizare Decizională

Formula 1 reprezintă apogeul competiției automobilistice mondiale, unde performanța nu este determinată exclusiv de viteza brută a monopostului sau de abilitatea tehnică a pilotului, ci într-o măsură semnificativă de calitatea deciziilor strategice luate în timp real pe parcursul cursei. Dintre toate deciziile strategice, momentul și modalitatea executării pit stop-urilor constituie factorul cu cel mai mare impact asupra rezultatului final.

Un pit stop în Formula 1 este o manevră complexă prin care pilotul intră la boxe pentru schimbarea anvelopelor, ajustări tehnice sau reparații. Deși durata fizică a unui pit stop este de aproximativ 2-3 secunde (timpul efectiv de schimbare a anvelopelor), timpul total pierdut pe circuit - incluzând decelerarea, traversarea pit lane-ului și reaccelerarea - variază între 20 și 28 de secunde, în funcție de caracteristicile circuitului.

Această pierdere de timp trebuie compensată prin câștigul de performanță obținut cu anvelope noi, mai aderente. Problema devine astfel una de optimizare multi-obiectiv: minimizarea timpului pierdut la boxe, maximizarea performanței anvelopelor pe parcursul stint-ului și gestionarea degradării progresive a compusului de cauciuc.

1.2 Importanța Strategiei de Pit Stop în Performanța de Cursă

Strategia de pit stop influențează rezultatul cursei prin multiple mecanisme:

A. Impact Direct asupra Timpului Total: O decizie suboptimă de pit stop poate costa între 10 și 30 de secunde, echivalentul a 3-5 poziții în clasament. Exemplu concret: dacă un pilot pit-uiște prea devreme, anvelopele noi vor avea performanță superioară, dar va pierde timp în trafic; dacă pit-uiște prea târziu, degradarea excesivă a anvelopelor va genera timpi pe tur semnificativ mai slabi.

B. Tactici Competitive - Undercut și Overcut: Undercut presupune că pilotul pit-uiște cu 1-2 tururi înaintea adversarului direct, beneficiind de anvelope proaspete pentru a realiza tururi rapide și a depăși adversarul în momentul în care acesta va intra la boxe. Overcut presupune că pilotul rămâne pe pistă mai mult decât adversarul, sperând că degradarea anvelopelor adversarului va fi suficient de mare încât să permită depășirea după propriul pit stop.

C. Adaptarea la Evenimente Neprevăzute: Prezența mașinii de siguranță (Safety Car) sau a Virtual Safety Car-ului creează ferestre strategice în care pit stop-ul devine aproape gratuit din punct de vedere al timpului pierdut, deoarece toți piloții circulă cu viteză redusă.

1.3 Scopul și Obiectivele Proiectului

Prezentul proiect își propune să dezvolte un sistem de asistență decizională bazat pe machine learning pentru optimizarea strategiei de pit stop în Formula 1.

Obiective Tehnice:

1. Construirea unui dataset complet: Agregarea datelor telemetrice din toate cele 24 de curse ale sezonului 2024 de Formula 1, la nivel granular de tur individual pentru fiecare pilot.
2. Dezvoltarea unui pipeline de procesare: Implementarea unui flux automatizat de extragere, curățare, îmbogățire și transformare a datelor brute în caracteristici relevante pentru modelarea machine learning.
3. Crearea unui model predictiv: Antrenarea unui clasificator probabilistic capabil să estimeze momentul optim al pit stop-ului și compusul de anvelope recomandat.
4. Validarea empirică: Evaluarea performanței modelului pe date nevăzute, utilizând metrice specifice clasificării binare și calibrării probabilistice.

2. Arhitectura Pipeline-ului de Colectare a Datelor

2.1 Viziune de Ansamblu

Pipeline-ul de procesare a datelor este structurat în straturi (layers), inspirat de arhitectura medallion utilizată în data engineering modern:

- **Bronze Layer (Date Brute):** Extragerea directă din API-uri externe (FastF1, Ergast, Meteostat)
- **Silver Layer (Date Curățate):** Procesarea, validarea și îmbogățirea datelor brute
- **Gold Layer (Date Analitice):** Dataset final optimizat pentru machine learning

Această arhitectură asigură trasabilitate (fiecare transformare este documentată și reproductibilă), modularitate (fiecare strat poate fi actualizat independent) și calitate (validări progresive reduc riscul de erori în datele finale).

2.2 Tehnologii și Biblioteci Utilizate

Pipeline-ul se bazează pe următoarele componente software:

FastF1 (v3.6.1): Bibliotecă Python specializată pentru accesarea datelor oficiale de telemetrie F1. Oferă acces la timpi pe tur, sectoare, date despre anvelope, evenimente de cursă. Utilizează cache local pentru optimizarea performanței.

Ergast API: API REST public pentru date istorice F1 (1950-prezent). Furnizează informații despre poziții pe grid, rezultate finale, durate pit stop-uri. Backup pentru datele care lipsesc din FastF1.

Meteostat: Bibliotecă pentru date meteorologice istorice. Îmbogățește contextul cu mediane anuale de temperatură și viteză vânt per circuit.

Pandas și NumPy: Manipularea tabelară a datelor, operații de agregare și transformare, calcule numerice eficiente.

3. Sursa și Structura Datelor

3.1 Universul de Date: Sezonul 2024

Proiectul se concentrează exclusiv pe sezonul 2024 al Campionatului Mondial de Formula 1, care a inclus 24 de curse desfășurate pe circuite din întreaga lume.

Nr.	Circuit	Locație	Tururi
1	Bahrain	Sakhir	57
2	Arabia Saudită	Jeddah	50
3	Australia	Melbourne	58
4	Japonia	Suzuka	53
5	China	Shanghai	56
6	Miami	SUA	57
7	Emilia Romagna	Imola	63
8	Monaco	Monte Carlo	78
9	Canada	Montreal	70
10	Spania	Barcelona	66
11	Austria	Spielberg	71
12	Marea Britanie	Silverstone	52
13	Ungaria	Budapesta	70
14	Belgia	Spa-Francorchamps	44
15	Olanda	Zandvoort	72
16	Italia	Monza	53
17	Azerbaidjan	Baku	55
18	Singapore	Singapore	62
19	Statele Unite	Austin	56
20	Mexic	Mexico City	71
21	Brazilia	Sao Paulo	71
22	Las Vegas	SUA	50
23	Qatar	Lusail	57
24	Abu Dhabi	Yas Marina	58

Totalul estimat este de aproximativ $1,400 \text{ tururi} \times 20 \text{ piloți} = \sim 28,000$ de înregistrări la nivel de tur individual.

3.2 Procesul de Extragere a Datelor

Funcția principală `load_fastfl_laps()` constituie nucleul pipeline-ului de extragere, fiind responsabilă pentru descărcarea și structurarea datelor telemetrice pentru o cursă specifică. Pentru fiecare tur al fiecărui pilot, se extrag:

Identificatori și Context: `race_id`, `year`, `circuit_name`, `driver_code`, `team`, `lap_number`, `position`

Timpi de Performanță: `lap_time_s`, `sector1_s`, `sector2_s`, `sector3_s` (converțiți în secunde pentru analize numerice)

Informații despre Anvelope: `compound` (SOFT/MEDIUM/HARD/INTERMEDIATE/WET), `tyre_age_laps`, `stint_id`

Indicatori de Pit Stop: `pit_in_flag`, `pit_out_flag` (0/1)

Date Meteorologice: `air_temp_c`, `track_temp_c`, `humidity`, `wind_speed_ms`, `wind_direction_deg`

Evenimente de Cursă: `safety_car_flag`, `virtual_sc_flag` (coduri TrackStatus FIA)

4. Ingineria Caracteristicilor (Feature Engineering)

Notebook-ul implementează trei funcții de feature engineering care transformă datele brute în caracteristici predictive:

4.1 Caracteristici Lag (Istoric)

Funcția `add_lag_features()` creează caracteristici bazate pe tururile anterioare: `lap_time_s_lag1` (timpul turului anterior), `lap_time_s_lag2` (timpul cu 2 tururi în urmă), `lap_time_s_lag3` (timpul cu 3 tururi în urmă). Aceste caracteristici permit modelului să detecteze tendințe de îmbunătățire sau degradare a performanței.

4.2 Estimarea Degradării

Funcția `add_degradation()` calculează panta regresiei liniare între numărul turului și timpul pe tur pentru fiecare stint. O valoare pozitivă indică degradare (timpul crește), o valoare negativă indică îmbunătățire, iar o valoare aproape de zero indică performanță stabilă.

4.3 Estimarea Pierderii de Timp la Pit Stop

Funcția `estimate_pit_loss()` calculează durata efectivă a pit stop-ului prin compararea timpului out-lap-ului cu mediana ultimelor 3 tururi curate. Valori tipice: pit stop perfect (20-22 secunde), pit stop lent (25-30 secunde), pit stop cu penalizare (30+ secunde).

5. Structura Finală a Datasetului

După procesare, datasetul final (`2024_season.csv`) conține:

- Număr de rânduri: 27,050 tururi
- Număr de coloane: 49 variabile
- Dimensiune fișier: 9.3 MB
- Curse acoperite: 24
- Piloți unici: 20-22 (variază per cursă)

PARTEA II: ANALIZA EXPLORATORIE A DATELOR (EDA)

6. Obiectivele Analizei Exploratorii

Analiza Exploratorie a Datelor (EDA) are rolul de a transforma datele brute într-o înțelegere profundă a pattern-urilor, relațiilor și anomaliilor care vor ghida deciziile de modelare ulterioară. EDA urmărește să răspundă la întrebări fundamentale despre calitatea datelor, distribuții și tendințe, relații între variabile, și pattern-uri specifice domeniului.

7. Inspecția Inițială a Datasetului

7.1 Dimensiuni și Structură

După încărcarea fișierului 2024_season.csv, obținem următoarele caracteristici: 27,050 rânduri (tururi), 49 coloane (variabile), 24 curse acoperite, 24 piloți unici (inclusiv piloți de rezervă), și 10 echipe.


Dimensiunea de 27,050 de tururi reprezintă agregarea tuturor tururilor parcurse de toți piloții în toate cele 24 de curse. Diferența față de valoarea teoretică de ~29,760 tururi se datorează abandonurilor și penalizărilor.

7.2 Categoriile de Variabile

Categorii	Variabile	Descriere
Identificatori	race_id, year, circuit_name, driver_code, team	Context cursă și pilot
Performanță	lap_time_s, sector1_s, sector2_s, sector3_s, position	Timpi și poziții
Anvelope	compound, tyre_age_laps, stint_id, degradation	Starea anvelopelor
Pit Stop	pit_in_flag, pit_out_flag, pit_stop_duration_s	Indicatori pit stop
Meteorologie	air_temp_c, track_temp_c, humidity, wind_speed	Condiții atmosferice
Evenimente	safety_car_flag, virtual_sc_flag	Evenimente de cursă
Derivate	lap_time_lag1/2/3, risk_score, in_battle_flag	Caracteristici inginerizate

8. Analiza Valorilor Lipsă

Analiza valorilor lipsă relevă 16 coloane cu date incomplete din totalul de 49. Majoritatea valorilor lipsă NU sunt erori de date, ci caracteristici structurale ale datelor de telemetrie F1.




pit_stop_duration_s (96.95% lipsă): Această variabilă este populată DOAR pe tururile de out-lap. Într-o cursă tipică, fiecare pilot face 1-3 pit stop-uri, deci din 27,050 tururi, doar ~850 sunt out-lap-uri (3.1%).

Variabile Lag (2.4%-5.8% lipsă): Variabilele lag necesită tururi anterioare pentru calcul. lag1 lipsește pentru primul tur, lag2 pentru primele 2 tururi, etc.

Timp pe Sectoare (0.1%-2.0% lipsă): Timpul pe sectoare lipsește pe in-lap-uri și out-lap-uri, când pilotul traversează pit lane-ul.

9. Distribuții ale Variabilelor Numerice



9.1 lap_time_s (Timpul pe Tur)


Medie: 91.50 secunde, Mediană: 86.56 secunde, Deviație standard: 60.15 secunde (foarte mare!), Minimum: 67.69 secunde, Maximum: 2526.25 secunde.


Deviația standard extrem de mare indică o distribuție foarte heterogenă, cauzată de variabilitatea între circuite (Monaco ~74s vs Spa ~107s) și tururi anormale (in-lap/out-lap, Safety Car, accidente).

9.2 tyre_age_laps (Vârsta Anvelopei)

Medie: 15.06 tururi, Mediană: 13 tururi, Q1: 7 tururi, Q3: 21 tururi, Maximum: 78 tururi.

Distribuția reflectă strategiile de pit stop: 25% din tururi au anvelope cu mai puțin de 7 tururi (imediat după pit stop), 75% au anvelope cu mai puțin de 21 tururi (zona critică pentru SOFT și MEDIUM).







9.3 degradation_s_per_lap (Rata de Degradare)

Medie: 1.15 s/tur, Mediană: 0.52 s/tur, Minimum: -25.06 s/tur (îmbunătățire), Maximum: 34.26 s/tur (degradare extremă).

Valorile negative nu înseamnă că anvelopele devin mai rapide, ci sunt cauzate de reducerea traficului, învățarea traseului, sau reducerea greutateii combustibilului.

10. Distribuții ale Variabilelor Categorice



10.1 compound (Tipul de Anvelopă)

Compus	Tururi	Procent	Utilizare Tipică
MEDIUM	14,339	53.0%	Stint principal, echilibru
HARD	9,097	33.6%	Stint lung, final de cursă
SOFT	1,633	6.04%	Calificări, stint scurt
INTERMEDIATE	1,944	7.2%	Condiții mixte (umed)
WET	37	0.16%	Ploaie torențială

10.2 safety_car_flag și virtual_sc_flag

Normal (fără SC): 96.0% din tururi, Safety Car: 3.9%, Virtual SC: 1.1%. Sub Safety Car, diferența de timp între piloți se reduce la aproape zero, reprezentând momentul ideal pentru pit stop cu un câștig net de 10-15 secunde.

PARTEA III: ANTRENAREA MODELULUI DE MACHINE LEARNING

11. Obiectivele Antrenării Modelului

Modelul de machine learning urmărește să răspundă la întrebări fundamentale: Va intra pilotul la boxe în următorul tur? Care este probabilitatea unui pit stop în următoarele 1-2 tururi? Ce factori influențează cel mai mult decizia de pit stop?

11.1 Abordarea Multi-Task Learning

Task 1 - Clasificare Binară: Variabilă țintă `pit_in_next_1` (0/1), prezice dacă pilotul va intra la boxe în turul următor.

Task 2 - Clasificare Multi-Clasă: Variabilă țintă `next_compound` (SOFT/MEDIUM/HARD), recomandă tipul de anvelopă pentru următorul stint.

Task 3 - Regresie: Variabilă țintă `remaining_stint_laps`, estimează durata rămasă a stint-ului curent.

12. Feature Engineering pentru Model

12.1 Crearea Variabilelor Țintă

Variabila `pit_in_next_1` este creată prin `shift(-1)` pe `pit_in_flag`, mutând valoarea cu o poziție înapoi. Distribuția clasei: doar 2.98% din tururi sunt urmate de un pit stop, rezultând un dezechilibru sever de clase (97.02% negativă vs 2.98% pozitivă).

12.2 Selecția Caracteristicilor

Au fost selectate 16 caracteristici pentru model, grupate în: progresul cursei (`lap_number`, `lap_progress_pct`, `remaining_laps`), starea anvelopelor (`tyre_age_laps`, `tyre_age_pct`), performanță (`position`, `degradation_s_per_lap`), evenimente de cursă (`safety_car_flag`, `virtual_sc_flag`, `in_battle_flag`), metrici de risc (`risk_score`), și tipul de anvelopă (`compound_dummies`).


13. Strategia de Împărțire Train/Test

13.1 Împărțirea Cronologi

Pentru a evita data leakage, datele sunt împărțite cronologic: 60% train (14 curse), 20% calibration (5 curse), 20% test (5 curse). Această abordare simulează deployment real, unde modelul prezice curse viitoare.

13.2 Gestionarea Dezechilibrului cu SMOTE

SMOTE (Synthetic Minority Over-sampling Technique) creează exemple sintetice pentru clasa minoritară prin găsirea celor mai apropiați k vecini și generarea de puncte noi pe linia dintre acestea. După aplicare, distribuția devine echilibrată: 50% clasa pozitivă.



14. Antrenarea și Compararea Modelelor

14.1 Modelele Testate

Model	Accuracy	Precision	Recall	F1	ROC-AUC	Brier
Logistic Regression	0.5618	0.0371	0.7984	0.0708	0.7351	0.2922
Random Forest	0.8222	0.0803	0.7177	0.1445	0.8652	0.1203
Gradient Boosting	0.8858	0.0952	0.5242	0.1611	0.8677	0.0731

Gradient Boosting este modelul câștigător cu cea mai bună acuratețe (88.58%), cea mai bună precizie (9.52%), și cel mai bun ROC-AUC (0.8677). Este un model conservator, dar precis, care evită alarme false.

15. Calibrarea Probabilităților

15.1 Problema Probabilităților Necalibrate

Modelele de machine learning nu produc întotdeauna probabilități bine calibrate. Înainte de calibrare, probabilitatea maximă era doar 94%, iar majoritatea predicțiilor erau concentrate în intervalul 0.15-0.35, făcând dificilă stabilirea unui threshold optim.

15.2 Soluția: Isotonic Regression

Isotonic Regression ajustează probabilitățile pentru a reflecta frecvențele reale. După calibrare, Brier Score s-a îmbunătățit de la 0.0731 la 0.0192, reprezentând o îmbunătățire de 73.8% în calitatea probabilităților.

16. Analiza Importanței Caracteristicilor

Rang	Caracteristică	Importanță	Interpretare
1	tyre_age_laps	32.45%	Vârsta anvelopelor - factor dominant
2	degradation_s_per_lap	18.76%	Rata de degradare - indicator critic
3	lap_progress_pct	14.32%	Progresul cursei - timing crucial
4	risk_score	9.87%	Scor compozit de risc
5	remaining_laps	7.65%	Tururi rămase - context strategic
6	position	6.54%	Poziția în cursă - tactică
7	safety_car_flag	5.43%	Safety Car - oportunitate

Decizia de pit stop este determinată în principal de starea anvelopelor (vârstă + degradare), factorii tactici (poziție, luptă) au rol secundar, iar evenimentele externe (Safety Car) creează oportunități.

PARTEA IV: GENERATORUL DE STRATEGIE

17. Introducere în Generatorul de Strategie

După antrenarea și calibrarea modelului, următorul pas constă în aplicarea practică pentru generarea de strategii de pit stop în scenarii simulate de cursă.

17.1 Arhitectura Generatorului

PolicyEngine: Motorul de decizie care încarcă modelul calibrat, aplică reguli de business (stint minim, ferestre de pit stop) și generează recomandări finale.

Track Profiles: Baza de date cu caracteristicile fiecărui circuit: număr de tururi, pierderea de timp la pit stop, rata de degradare tipică.

Race Simulator: Generează date sintetice pentru o cursă completă.

18. Profiluri de Circuite

Fiecare circuit are un profil definit cu parametri specifici:

Circuit	Tururi	Pit Loss (s)	Timp Mediu (s)	Degradare (s/tur)
Monaco	78	24.0	74.0	0.02
Monza	53	24.0	82.0	0.03
Qatar	57	22.0	85.0	0.08
Singapore	62	28.0	99.0	0.06
Silverstone	52	21.0	89.0	0.05

19. Configurarea Simulării

Utilizatorul poate configura parametri pentru diferite scenarii: circuit, poziția pe grid, compusul de start, tururile cu Safety Car, threshold de probabilitate, și stint minim.

19.1 Parametri Cheie

PROBABILITY_THRESHOLD = 0.18: După calibrare, probabilitățile sunt în intervalul 0.00-0.30. Tururi peste threshold primesc recomandare de pit stop.

MIN_STINT_LAPS = 10: Numărul minim absolut de tururi înainte de primul pit stop, prevenind recomandări nerealiste.

COMPOUND_PIT_OFFSET: SOFT: +0 tururi, MEDIUM: +7 tururi, HARD: +12 tururi față de baseline.

20. Logica de Decizie

Ierarhia deciziilor în generator:

5. **Prioritate 1 - Safety Car:** Dacă există tururi cu Safety Car după stint-ul minim, recomandare imediată. Câștig: 14 secunde!
6. **Prioritate 2 - Probabilitate Mare:** Dacă există tururi cu probabilitate $>$ threshold, se creează o fereastră de pit stop.
7. **Prioritate 3 - Vârful de Probabilitate:** Dacă niciun tur nu depășește threshold, se alege turul cu probabilitatea maximă.

21. Validarea Recomandărilor

Scenariul testat: Monaco, P3, HARD, Safety Car tururile 30-35.

Recomandarea modelului: Pit stop în turul 30 (primul tur cu Safety Car).

Validare:

- ✓ Respectă stint-ul minim (10 tururi)
- ✓ Profită de Safety Car (câștig 14 secunde)
- ✓ Anvelopele HARD cu 30 tururi = încă performante
- ✓ Decizie strategică corectă

CONCLUZII

Realizări Principale

Proiectul a demonstrat cu succes dezvoltarea unui sistem complet de asistență decizională pentru optimizarea strategiei de pit stop în Formula 1:

- Dataset complet: 27,050 tururi din 24 de curse, 49 variabile
- Pipeline reproductibil: Arhitectură medallion cu trasabilitate completă
- Model performant: Gradient Boosting cu ROC-AUC 0.8677
- Calibrare excelentă: Îmbunătățire 73.8% în Brier Score după calibrare isotonică
- Generator funcțional: Recomandări valide, realiste și competitive

Caracteristici Cheie Identificate

Analiza importanței caracteristicilor a identificat factorii decisivi:

8. **Vârsta Anvelopelor (32.45%):** Factor dominant în decizia de pit stop

9. **Rata de Degradare (18.76%):** Indicator de urgență pentru pit stop

10. **Progresul Cursei (14.32%):** Context temporal crucial

Limitări și Direcții Viitoare

Limitări identificate: Sezon unic (2024), lipsă date în timp real, dezechilibru sever de clase, lipsă informații strategice (comunicații echipă).

Îmbunătățiri propuse: Feature engineering avansat (interacțiuni, gap față de adversar), simulare multi-stint cu adversari, model non-linear de degradare (cliff effect), și integrare cu date în timp real.

Contribuția Proiectului

Acest proiect demonstrează aplicabilitatea practică a tehnicilor de machine learning în domeniul sporturilor cu motor. Sistemul dezvoltat poate servi ca bază pentru:

- Instrumente de asistență decizională pentru echipele de F1
- Platforme de simulare pentru antrenamentul strategilor
- Aplicații educaționale pentru înțelegerea strategiei de cursă
- Cercetare academică în optimizare decizională sub incertitudine

BIBLIOGRAFIE

[1] FastF1 Documentation, <https://docs.fastf1.dev/>, accesat ianuarie 2025

[2] Ergast Developer API, <https://ergast.com/mrd/>, accesat ianuarie 2025

[3] Scikit-learn: Machine Learning in Python, Pedregosa et al., JMLR 12, pp. 2825-2830, 2011

[4] Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets, Lemaître et al., JMLR 18, pp. 1-5, 2017

[5] Calibration of Machine Learning Models, Niculescu-Mizil & Caruana, ICML 2005

[6] Gradient Boosting Machines: A Tutorial, Natekin & Knoll, Frontiers in Neurorobotics, 2013

[7] Formula 1 Technical Regulations 2024, FIA, <https://www.fia.com/>

[8] Meteostat Python Library, <https://meteostat.net/>, accesat ianuarie 2025

[9] Pandas: Powerful Data Structures for Data Analysis, McKinney, 2010

[10] SMOTE: Synthetic Minority Over-sampling Technique, Chawla et al., JAIR 16, pp. 321-357, 2002