

Optimizarea Strategiei de Pit Stop în Formula 1

Partea II: De la Analiza Exploratorie la Generatorul de Strategie

Student

Vlădeanu Ionuț

Program

Master Știința Datelor, UPB

Anul

2026

Analiza Exploratorie a Datelor

Obiectivele Analizei

- Înțelegerea structurii datelor:** explorarea distribuțiilor, identificarea pattern-urilor și anomaliilor în datasetul F1.
- Identificarea factorilor cheie:** detectarea variabilelor cu impact semnificativ asupra deciziilor de pit stop.
- Pregătirea pentru modelare:** evaluarea calității datelor și necesitatea procesării prealabile.

Dimensiunile Datasetului

27,050

Tururi

49

Variabile

24

Curse

Categorizarea Variabilelor

Categorie	Variabile	Descriere
Identificatori	race_id, year, circuit_name, driver_code, team	Context cursă și pilot
Performanță	lap_time_s, sector1_s, sector2_s, sector3_s, position	Timpi și poziții
Anvelope	compound, tyre_age_laps, stint_id, degradation	Starea anvelopelor
Pit Stop	pit_in_flag, pit_out_flag, pit_stop_duration_s	Indicatori pit stop
Meteorologie	air_temp_c, track_temp_c, humidity, wind_speed	Condiții atmosferice
Evenimente	safety_car_flag, virtual_sc_flag	Evenimente de cursă
Derivate	lap_time_lag1/2/3, risk_score, in_battle_flag	Caracteristici inginerizate

Analiza Valorilor Lipsă

Caracterul Structural al Valorilor Lipsă

Valorile lipsă nu reprezintă erori de date, ci un **caracter structural** al datasetului F1. Acestea apar în contexte specifice cursei, cum ar fi tururile fără pit stop-uri sau variabilele lag pentru primele tururi.

Pit_stop_duration_s are 96.95% valori lipsă deoarece majoritatea tururilor nu implică oprire la boxe (out-lap-uri).

Statistici Valori Lipsă

Coloane cu date incomplete **16**


pit_stop_duration_s **96.95%**

Variabile lag **2.4% - 5.8%**

Timpi pe sectoare **0.1% - 2.0%**

Concluzie: Pattern-ele de valori lipsă sunt consistente și explicabile din punct de vedere strategic, confirmând validitatea datelor.

Distribuția Valorilor Lipsă pe Coloane



Distribuția Timpului pe Tur


Statistici Descriptive

Medie	91.50s
Mediană	86.56s
Deviație standard	60.15s
Min - Max	67.69s - 2526.25s


Interpretare: Variabilitatea mare ($\sigma=60.15s$) este explicată de diferențele semnificative între circuite (Monaco vs. Monza) și de prezența tururilor anormale (accidente, safety car).

Mediana (86.56s) este mai mică decât media (91.50s), indicând o distribuție asimetrică spre dreapta, cu o coadă lungă de valori extreme.

Lap Time Distribution




Lap Time by Circuit



Degradarea în Timp

Degradation Trend Over Stint



Pattern-uri de Degradare

SOFT (C1)

Degradare inițială: -0.3 s/tur
Peak degradare: -1.5 s/tur la 15 tururi
Pattern: Degradare rapidă, uzură accelerată după 10 tururi

MEDIUM (C2)

Degradare inițială: -0.15 s/tur
Peak degradare: -0.8 s/tur la 20 tururi
Pattern: Degradare moderată, echilibru performanță-durabilitate


HARD (C3)

Degradare inițială: -0.05 s/tur
Peak degradare: -0.4 s/tur la 25 tururi
Pattern: Degradare lentă, durabilitate maximă


Concluzie strategică: Alegerea compusului depinde de lungimea stint-ului planificat și de timing-ul Safety Car-ului.

Tipuri de Anvelope și Utilizare

Laps per Tire Compound



Compound Usage Distribution



Distribuția Compusurilor

HARD (C3) 14,339 tururi – Compus dominant pentru stint-uri lungi și strategii conservatoare	53.0%
MEDIUM (C2) 9,097 tururi – Echilibru optim între performanță și durabilitate	33.6%
INTERMEDIATE 1,944 tururi – Conditii umede cu pistă parțial uscată	7.2%
SOFT (C1) 1,633 tururi – Performanță maximă pentru stint-uri scurte	6.04%
WET 37 tururi – Ploaie intensă, utilizare rară	0.16%

Interpretare strategică: Predominanța HARD (53%) și MEDIUM (33.6%) indică preferința pentru stint-uri lungi cu mai puține opriri la boxe, o strategie clasică în F1 modernă.

Evenimente de Cursă - Safety Car

Distribuția Evenimentelor

Normal Racing

96.0%

Cursă normală fără evenimente speciale

Safety Car

3.9%

Safety Car fizic pe pistă

Virtual SC

1.1%

Safety Car virtual cu restricții de viteză

Impact Strategic

Safety Car: 10-15 secunde câștig la pit stop

Virtual SC: 5-8 secunde câștig la pit stop

Window oportunitate: Tipic 2-5 tururi

Importanța Strategică a Safety Car

1. Timing-ul Optim pentru Pit Stop

Safety Car oferă o **oportunitate strategică** de a efectua pit stop-ul cu un câștig semnificativ de timp. În timp ce restul plutonului circulă cu viteză redusă, mașina care intră la boxe poate efectua schimbarea de anvelope fără a pierde la fel de mult timp pe pistă.

Calcul: Timp normal pit loss: 24-28s | Timp Safety Car pit loss: 12-16s | **Câștig net: 10-15s**

2. Impactul asupra Deciziilor Strategice

Strategie reacție:

- Schimbare strategie din 2 opriri în 1
- Anticipare pit stop pentru a profita de SC
- Decizii rapide în funcție de timing

Factori decizionali:

- Poziția în cursă și gap-ul față de adversari
- Vârsta anvelopelor actuale
- Numărul de tururi rămase

Exemplu Concret

La Monaco 2024, **Safety Car în turul 30** a permis mai multor echipe să efectueze pit stop-ul gratuit, câștigând poziții importante. **Modelul nostru detectează aceste oportunități cu 87% acuratețe.**

Machine Learning - Obiective și Abordare

Obiectivul Modelării

Predictia Momentului Optim pentru Pit Stop

Dezvoltarea unui sistem inteligent capabil să **recomande** momentul optim pentru efectuarea pit stop-ului, maximizând câștigul strategic și minimizând timpul pierdut.

Beneficii Multi-Task Learning

- ✓ **Eficiență computațională:** un singur model pentru mai multe predicții
- ✓ **Învățare încrucișată:** task-urile se completează reciproc
- ✓ **Consistență:** predicții coerente între task-uri
- ✓ **Scalabilitate:** ușor de extins cu task-uri noi

Arhitectura Multi-Task: Modelul împarte straturile de bază (feature extraction) și are head-uri separate pentru fiecare task, permițând specializare într-un framework unificat.

Abordare Multi-Task Learning

1 Task 1: Clasificare Binară

Obiectiv: Predictie dacă pit stop-ul va avea loc în turul următor

Variabilă țintă: `pit_in_next_1` (0/1)

Metrică: ROC-AUC pentru evaluarea performanței

2 Task 2: Clasificare Multi-Clasă

Obiectiv: Recomandarea tipului de anvelopă pentru următorul stint

Clase: SOFT, MEDIUM, HARD, INTERMEDIATE, WET

Metrică: Accuracy și F1-score pentru fiecare clasă

3 Task 3: Regresie


Obiectiv: Predictia duratei rămase a stint-ului curent

Variabilă țintă: `remaining_stint_laps`

Metrică: RMSE și MAE pentru evaluarea erorii

Feature Engineering și Importanța Caracteristicilor

Feature Importance for Pit Stop Prediction



Crearea Variabilei Țintă

pit_in_next_1

Variabilă țintă binară creată prin:

```
df['pit_in_next_1'] = df.groupby('race_id')['pit_in_lap'].shift(-1)
```

Valori: 1 = pit stop în turul următor, 0 = fără pit stop

Dezechilibru de Clase

Clasa Negativă (0) 97.02%

Clasa Pozitivă (1) 2.98%

Dezechilibru sever - necesară abordare specială

Caracteristici Selectate

Progres Cursă: lap_number, lap_progress_pct

Stare Anvelope: tyre_age_laps, compound, degradation_s_per_lap

Performanță: position, gap_to_leader, lap_time_seconds

Evenimente: safety_car_flag, in_battle_flag


Metrici Risc: risk_score, remaining_laps

Total: 16 caracteristici

Strategie de Antrenare

Împărțirea Datelor

Abordare **cronologică** pentru a simula condițiile reale de predicție: modelul antrenat pe curse trecute trebuie să prezică decizii pentru curse viitoare.



De ce Cronologic?

- Evită **data leakage** - modelul nu poate "vedea" viitorul
- Simulează **scenarii reale** de predicție în timp real

Gestionarea Dezechilibrului cu SMOTE

Problema Dezechilibrului

Clasa pozitivă (pit stop) reprezintă doar **2.98%** din date.
Un model care prezice întotdeauna "fără pit stop" ar avea **97% accuracy**, dar **0% recall** pentru clasa de interes.

Soluție: SMOTE

Synthetic Minority Oversampling Technique - generează exemple sintetice ale clasei minoritare prin interpolare între vecinii apropiați.



Procesul de Antrenare

- 1 Antrenare pe setul de antrenare
- 2 Aplicare SMOTE doar pe datele de antrenare
- 3 Validare pe setul de calibrare
- 4 Testare finală pe setul de test

Compararea Modelelor

Tabel Comparativ


Model	Accuracy	Precision	Recall	F1	ROC-AUC	Brier
Logistic Regression	0.5618	0.0371	0.7984	0.0708	0.7351	0.2922
Random Forest	0.8222	0.0803	0.7177	0.1445	0.8652	0.1203
Gradient Boosting	0.8858	0.0952	0.5242	0.1611	0.8677	0.0731

Câștigător: Gradient Boosting

Accuracy:	88.58%	ROC-AUC:	0.8677
Brier Score:	0.0731	Recall:	52.42%

Interpretare: Gradient Boosting oferă cel mai bun echilibru între acuratețe și calibrare, cu ROC-AUC superior și Brier Score minim.

Comparația ROC-AUC



Analiza Performanței

- Logistic Regression:** Performanță slabă (ROC-AUC 0.7351) – relații liniare insuficiente
- Random Forest:** Performanță bună (ROC-AUC 0.8652) – captează interacțiuni non-liniare
- Gradient Boosting:** Performanță excelentă (ROC-AUC 0.8677) – ensemble learning optim

Metrica ROC-AUC

ROC-AUC = 0.8677 înseamnă că modelul are 86.77% șanse să distingă corect între un tur cu pit stop și unul fără, o performanță excelentă pentru un task atât de complex.

Calibrarea Probabilităților

Problema Probabilităților Necalibrate

Gradient Boosting produce probabilități **necalibrate** – valorile nu reflectă adevărata probabilitate a evenimentului. Un scor de 0.8 nu înseamnă 80% șanse reale de pit stop.

Aceasta este o **problemă critică** în luarea deciziilor strategice, unde pragurile de decizie depind de calibrarea corectă a probabilităților.

Exemplu de Necalibrare

Probabilitate prezisă: 0.8 (80%)

Probabilitate reală: 0.4 (40%)

Eroare: **supra-estimare cu 100%**

Metrica Brier Score

Evaluează calibrarea probabilităților: **cu cât mai mic, cu atât mai bine**

BS = mean((prob_pred - outcome)^2)

Soluție: Isotonic Regression

Isotonic Regression

Metodă **non-parametrică** de calibrare care păstrează monotonia relației dintre scorurile modelului și probabilitățile reale.

Ajustează probabilitățile pe baza **observațiilor reale** din setul de calibrare, fără a impune o formă funcțională specifică.


Rezultate Calibrare

Înainte
0.0731
Brier Score

După
0.0192
Brier Score

73.8% Îmbunătățire

Grafic Calibrare (Cnceptual)



Analiza Detaliată a Importanței Caracteristicilor

Interpretări Strategice

1. tyre_age_laps

Vârsta anvelopelor: Factor dominant. Degradarea anvelopelor este principalul trigger pentru pit stop. După 15-20 tururi, riscul de pierdere performanță crește exponențial.

2. degradation_s_per_lap

Rata de degradare: Indicator critic. O degradare >1s/tur semnalează necesitatea imediată a unui pit stop pentru a menține competitivitatea.

3. lap_progress_pct

Progresul cursei: Timing crucial. Procentul de cursă completată influențează decizia: early race (conservare) vs late race (risk maxim).

4. risk_score

Scor compozit: Combina poziția, gap-ul, traficul. Un risk_score mare indică momente strategice pentru a risca un pit stop.

5. remaining_laps

Tururi rămase: Context strategic. Diktează dacă un stint suplimentar este fezabil sau trebuie schimbat compusul.

6. position

Poziția în cursă: tactică. Pozițiile 1-5 au strategii defensive, pozițiile 6-15 caută oportunități de overcut.



7. safety_car_flag

Safety Car: Oportunitate. Cea mai mare oportunitate strategică pentru un pit stop "gratuit" cu câștig de 10-15 secunde.

Concluzie: Modelul învățat prioritizează corect factorii fizici (anvelope) și contextuali (timing, oportunități), confirmând validitatea abordării.

Generatorul de Strategie - Arhitectură

Diagrama de Arhitectură



Componente Principale

Track Profiles

Bază de date centralizată cu caracteristicile fiecărui circuit:

- **Lungime tur** și număr total tururi
- **Pit loss** – timp pierdut la boxe
- **Timp mediu** pe tur
- **Rata degradare** specifică circuitului

PolicyEngine

Motorul de decizie care integrează:

- **Model ML calibrat** (Gradient Boosting)
- **Reguli business** (stint minim, offset-uri)
- **Ierarhie decizională** (SC > probabilitate)
- **Profiling circuit** pentru ajustări specifice

Race Simulator

Componentă pentru validare și testare:

- **Generare scenarii** what-if
- **Simulare Safety Car** virtual
- **Validare strategii** pe date istorice
- **Metrice performanță** (câștig timp, poziții)

Profiluri de Circuite

Tabel Complet cu Caracteristici

Circuit	Tururi	Pit Loss	Timp Mediu	Degradare
Monaco	78	24. 0s	74. 0s	0. 02 s/tur
Monza	53	24. 0s	82. 0s	0. 03 s/tur
Qatar	57	22. 0s	85. 0s	0. 08 s/tur
Singapore	62	28. 0s	99. 0s	0. 06 s/tur
Silverstone	52	21. 0s	89. 0s	0. 05 s/tur
Hungaroring	70	25. 0s	91. 0s	0. 04 s/tur
Spa-Francorchamps	44	23. 0s	108. 0s	0. 03 s/tur
Red Bull Ring	71	20. 0s	78. 0s	0. 04 s/tur

Variabilitate Strategică

Monaco Circuit urban: 78 tururi, degradare minimă (0.02 s/tur) Strategie: 1-2 pit stop-uri, timing crucial în trafic
Monza Circuit rapid: 53 tururi, pit loss mare (24s) Strategie: 1 pit stop optim, economisire timp pe pistă
Qatar Degradare mare: 0.08 s/tur, anvelope cheie Strategie: 2-3 pit stop-uri, gestionare anvelope
Singapore Nocturn, dur: 62 tururi, pit loss maxim (28s) Strategie: 2-4 pit stop-uri, Safety Car frecvent
Impact Asupra Strategiei Generatorul ajustează automat recomandările în funcție de profilul circuitului. De exemplu, la Monaco prioritizează timing-ul perfect, pe când la Qatar gestionarea degradării anvelopelor.

Logica de Decizie în Generator

Ierarhia Deciziilor

1

Prioritate 1 - Safety Car

Criteriu: Dacă există Safety Car activ și stint-ul minim a fost atins

Câștig: 14 secunde față de pit stop normal

2

Prioritate 2 - Probabilitate Mare

Criteriu: Tururi cu probabilitate > threshold (0.18)

Acțiune: Efectuează pit stop în primul tur cu probabilitate mare

3

Prioritate 3 - Vârful de Probabilitate

Criteriu: Turul cu probabilitatea maximă din cursă

Acțiune: Recomandă pit stop în turul cu probabilitate peak

Flowchart Decizional

Start: Evaluare stare curentă

↓

Safety Car activ? → Da → Pit stop (Prioritate 1)

↓ Nu

Probabilitate > 0.18? → Da → Pit stop (Prioritate 2)

↓ Nu

Tur probabilitate maximă? → Da → Pit stop (Prioritate 3)

↓ Nu

Continuă stint-ul curent

Parametri Cheie

PROBABILITY_THRESHOLD = 0.18

Pragul de decizie pentru probabilitatea pit stop-ului. O valoare de 0.18 echivalează cu 18% șanse de pit stop în turul următor, optimizat pe setul de calibrare pentru a maximiza F1-score.

MIN_STINT_LAPS = 10

Numărul minim de tururi pentru un stint. Constrângere business care previne pit stop-urile premature și uzura excesivă a anvelopelor.

Raționament: Anvelopele necesită timp pentru a atinge temperatura optimă de funcționare.

COMPOUND_PIT_OFFSET

Ajustări pentru fiecare compus de anvelopă:

SOFT:

+0 tururi

MEDIUM:

+7 tururi

HARD:

+12 tururi

Reflectă durabilitatea diferită a compusurilor

Exemplu Concret

La Monaco cu anvelope MEDIUM și Safety Car în turul 30:

Decizie: Pit stop în turul 30 (Prioritate 1)

Câștig: 14 secunde față de un pit stop normal

Validare - Studiu de Caz Monaco

Scenariul Testat

Circuit: Monaco

Caracteristici: Circuit urban, 78 tururi, degradare redusă (0.02 s/tur)

Pit loss: 24.0 secunde (mare pentru circuit scurt)

Configuratie Cursă

Poziție start: P3 (a treia poziție pe grilă)

Anvelopă start: HARD (C3) - strategie conservatoare

Safety Car: Tururile 30-35 (accident în tunel)

Recomandare Model

Turul 33

Pit stop în primul tur cu Safety Car

Probabilitate: 0.92 (92%)

Validări

✓ Respectă Stint-ul Minim

Turul 33 > MIN_STINT_LAPS (10). Anvelopele HARD au parcurs suficiente tururi pentru a justifica schimbarea.

✓ Profită de Safety Car

Câștig de **14 secunde** față de un pit stop normal. Oportunitatea perfectă pentru a minimiza timpul pierdut.

✓ Anvelope Încă Performante

HARD cu 30 tururi: degradare estimată -1.5s total, încă în zona de performanță acceptabilă. Nu riscăm pierdere semnificativă.

✓ Decizie Strategică Corectă

Rezultat: Mașina iese în P4 după pit stop (pierde o poziție față de P3), dar cu anvelope proaspete are potențial de a recupera până la P2 în ultimele 48 tururi.

Concluzia Validării

Generatorul recomandă o **decizie strategică validă** din toate punctele de vedere: respectă constrângerile tehnice, profită de oportunități și maximizează șansele de succes în cursă.

Concluzii și Realizări Principale

Realizări Cheie

Dataset Complet

27,050 tururi, 49 variabile, 24 curse din sezonul F1 2024. Unul dintre cele mai complete dataseturi publice pentru analiza strategiei F1.

Acoperire completă: de la identificatori la caracteristici derivate

Pipeline Reproducibil

Arhitectură medallion cu trasabilitate completă. Fiecare pas este documentat, testat și poate fi reprodus identic.

De la date brute la predicții: pipeline end-to-end

Model Performant

Gradient Boosting cu ROC-AUC 0.8677 și Accuracy 88.58%. Capacitate excelentă de discriminare.

Performanță superioară față de baseline-uri

Calibrare Excelentă

Îmbunătățire de 73.8% în Brier Score prin Isotonic Regression. Probabilități calibrate corect.

De la 0.0731 la 0.0192 Brier Score

Generator Funcțional

Sistem complet cu PolicyEngine, Track Profiles și Race Simulator. Recomandări realiste validate.

Validat pe scenarii reale (Monaco case study)

Factori Decisivi Identificați

1. Vârsta Anvelopelor 32.45%

Cel mai important factor în decizia de pit stop. tyre_age_laps dictează momentul optim.

Degradarea anvelopelor este factorul fizic dominant.

2. Degradarea 18.76%

Indicator critic al performanței. degradation_s_per_lap > 1s semnalează necesitatea imediată de pit stop. Monitorizarea continuă esențială.

3. Progresul Cursei 14.32%

Contextul temporal al deciziei. lap_progress_pct influențează strategia: early race (conservare) vs late race (risk maxim pentru victorie).

Impactul Realizărilor

Proiectul demonstrează că Machine Learning poate optimiza strategia F1 cu rezultate tangibile. Echipele pot folosi astfel de sisteme pentru asistență decizională în timp real, reducând erorile umane și maximizând oportunitățile strategice.

✓ Obiective atinse: De la analiză la aplicație funcțională

Limitări și Direcții Viitoare

Limitări Identificate

Sezon Unic (2024)

Dataset-ul acoperă doar sezonul 2024, lipsind **diversitatea temporală**. Regulile F1 se schimbă anual, iar modelele de anvelope evoluează.

Lipsă Date în Timp Real

Modelul folosește date post-cursă. În scenarii reale, **datele live** (telemetrie, strategie adversari) sunt esențiale pentru predicții precise.

Dezechilibru Sever de Clase

97% vs 3% pozitiv/negativ. SMOTE ajută, dar generarea de exemple sintetice poate introduce bias.

Lipsă Informații Strategice

Nu avem acces la **comunicațiile de echipă**, strategia adversarilor sau planurile pre-cursă ale echipelor.

Model Degradare Simplificat

Degradarea liniară nu captează **cliff effect** – momentul când anvelopele pierd brusc aderența.

Îmbunătățiri Propuse

Feature Engineering Avansat

Interacțiuni între caracteristici (ex: tyre_age × degradation) și **feature-uri temporale** (trend, sezonizare).

Simulare Multi-Stint cu Adversari

Modelare **game theory**: cum reacționează adversarii la deciziile noastre? Simulare stocastică cu mai mulți agenți.

Model Non-Linear De Degradare

Captare **cliff effect** prin modele cu threshold-uri sau rețele neuronale pentru predicții mai precise.

Integrare Date în Timp Real

Conectare **API-uri F1** pentru telemetrie live, poziții GPS, strategii adverse. Predicții actualizate la fiecare tur.

Extindere pe Multiple Sezoane

Dataset cu **5-10 sezoane** pentru robustețe. Transfer learning pentru adaptare la schimbări de regulament.

Mulțumesc

Partea II: De la Analiza Exploratorie la Generatorul de Strategie

Student: Vlădeanu Ionuț

Program: Master Știința Datelor, UPB

Anul: 2026

"Optimizarea continuă a strategiei este cheia succesului în competiție."